

U-Net - Backbone Paper Review

홍창희, 박민선, 임우진

July. 18. 2025

Medical AI Research Center

Contents

01
Background

02
Introduction

03
Methodology

04
Experiments

05
Application in the
Medical Domain

Contents

01
Background

02
Introduction

03
Methodology

04
Experiments

05
Application in the
Medical Domain

Background

Segmentation


- 입력 이미지의 모든 픽셀에 대해 **Classification** 해, 각 픽셀이 어느 클래스에 속하는지 라벨 할당 → 분할



Input

Segmented


- 1: Person
- 2: Bench
- 3: Plant/Grass
- 4: Cat




Semantic Labels

Semantic vs Instance (Segmentation)

- Semantic - 같은 클래스 내부에서 객체 구분 불가능
- Instance - 같은 클래스 내부에서 객체 구분 가능



Semantic Segmentation




Instance Segmentation


Background

Biomedical Image Segmentation

- 의료 또는 생물학 연구에서 얻은 영상(X-ray, CT, MRI, 현미경 사진 등) 내의 특정 구조물(장기, 종양, 세포, 혈관 등)을 **픽셀 단위**로 정확하게 **식별**하고 **경계**를 나누는 기술
- U-Net에선 주로 **세포** 구조를 분할
- 현미경 영상과 같은 **미세 구조**를 다루는 영상에서 픽셀 단위의 **Segmentation**이 중요



input



output

White = 세포
Black = 세포막

Contents

01
Background

02
Introduction

03
Methodology

04
Experiments



05
Application in the
Medical Domain

Introduction

Before U-Net

• DNN + Sliding Window

- VGGNet처럼 conv layer들을 거친 후 최하단에 **FC layer**를 놓아 Classification 하는 CNN 모델을 사용해, 이미지의 한 픽셀 주변값(patch)을 입력으로 받아 중앙의 한 픽셀의 클래스를 출력(부여)하는 방식
- 모든 픽셀마다 네트워크가 독립적으로 수행돼 속도가 느리고, 각 패치마다 겹치는 부분이 많아 중복으로 인한 낭비가 심함
- 공간 context를 확보하기 위해 **patch 크기를 늘리면** 더 많은 **max pooling**을 거쳐야하므로 **localization 정확도가 떨어짐** (trade-off)





Introduction

Before U-Net

● FCN: Fully Convolutional Network


- 기존 방식을 완전히 개편하여 **FC layer**를 없애고 모두 **1x1 conv layer**로 대체해, **이미지 전체를 입력으로 받아 전체 공간 특징맵(segmentation)**을 출력하는 모델
- Semantic Segmentation을 위해 제안됨
- 이 Base model을 수정, **확장**하여 제안된 모델이 **U-Net**



Introduction

Idea of U-Net

- U자형 대칭 인코더-디코더 구조
- 고해상도 특징의 연결을 통한 Skip Connection
- Transposed Convolution (Up-Convolution)을 통한 업샘플링
- Overlap-Tile, Mirroring
- Weighted Loss, Data augmentation



Contents

01
Background

02
Introduction

03
Methodology


04
Experiments

05
Application in the
Medical Domain

Architecture

Contracting Path


- 각 Step마다 3x3 conv를 두 차례씩 반복 (패딩x)
- conv layer에는 ReLU 연산이 포함
- conv 이후엔 2x2 max-pooling (stride:2)
- Down-sampling마다 채널 수를 2배로 늘림



Architecture

● Expansive Path

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남
- 3x3 conv를 두 차례씩 반복 (패딩 x)
- conv layer에는 ReLU 연산이 포함
- Up-conv된 feature map은 **Contracting path**에서 **cropped된 feature map**과 **concat** 시킴 (Skip Connection)
- 마지막 레이어로 **1x1 conv**를 통해 Segmentation map 출력 (필터 개수 = 총 클래스 수)




Architecture

- Expansive Path

- ✓ Transposed convolution

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남




Architecture

- Expansive Path

- ✓ Transposed convolution

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남




Architecture

- Expansive Path

- ✓ Transposed convolution

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남




Architecture

- Expansive Path

- ✓ Transposed convolution

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남




Architecture

- Expansive Path

- ✓ Transposed convolution

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남




Architecture

- Expansive Path

- ✓ Transposed convolution

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남




Architecture

- Expansive Path

- ✓ Transposed convolution

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남




Architecture

- Expansive Path

- ✓ Transposed convolution

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남




Architecture

- Expansive Path


- ✓ Transposed convolution

- 각 Step마다 **2x2 Up-conv**(stride: 2)을 통해 feature map의 해상도가 2배로 늘어남




Overlap-Tile

- 크기가 큰 이미지의 경우엔 GPU **Memory**가 **부족**한 문제가 있으므로, 이미지 전체를 사용하는 대신 이미지를 각각의 **Tile**로 나눠 segmentation
- 하단의 사진과 같이 이미지를 타일로 나눠서 입력으로 사용
- segmentation을 위해 각 **tile**의 **주변 픽셀**을 같이 입력받기 때문에, 다음 tile에 대한 segmentation을 얻기 위해서는 **이전 입력**의 일부분이 **포함**됨 (overlap)
- 이미지의 **경계 부분 픽셀**에 대한 segmentation을 위해 **미러링**을 이용한 **Extrapolation** 기법 사용




Mirroring Extrapolate

- 이미지의 **경계 부분 픽셀**에 대한 segmentation을 위해 0이나 임의의 패딩값을 사용하는 대신 이미지 경계 부분의 **미러링**을 이용한 **Extrapolation 기법** 사용
- 주요 데이터셋이 **세포**이므로, 세포의 특성에 따라 높은 성능을 낼 수 있음



■ Data augmentation - Elastic deformation



조직의 자연스러운 변형을 모사하여 실제 생의학 데이터에서의 변형에 대한 불변성 학습

Training - 손실함수를 픽셀마다의 구한 에너지 평선의 총합으로 구현




Fig.3. HeLa cells on glass recorded with DIC (differential interference contrast) microscopy.

(a) raw image.

(b) overlay with ground truth segmentation. Different colors indicate different instances of the HeLa cells.

(c) generated segmentation mask (white: foreground, black: background).

(d) map with a pixel-wise loss weight to force the network to learn the border pixels.

■ Training - 손실함수를 픽셀마다의 구한 에너지 평선의 총합으로 구현

$$p_{l,x}(x) = \frac{e^{z_{l,x}}}{\sum_j e^{z_{j,x}}}$$

$$\log(p_{l,x}(x))$$

$$E = \sum_{\mathbf{x} \in \Omega} w(\mathbf{x}) \log(p_{\ell(\mathbf{x})}(\mathbf{x}))$$

$$w(\mathbf{x}) = w_c(\mathbf{x}) + w_0 \cdot \exp\left(-\frac{(d_1(\mathbf{x}) + d_2(\mathbf{x}))^2}{2\sigma^2}\right)$$

1) SoftMax를 사용하여 예측값을 확률로 변환

픽셀단위 예측값에 SoftMax 함수 P를 적용하여, 각 클래스에 속할 확률을 계산

2) 로그 확률 계산 (Cross Entropy Loss 적용)

정확한 예측일수록 손실이 작고 잘못된 예측일수록 손실이 커짐

3) 픽셀별 Weight 적용하여 Loss 계산

경계선 픽셀을 더 강하게 학습하기 위해 Cross Entropy Loss에 픽셀 고유의 Weight $w(x)$ 를 곱함

4) Weight Map 설계

가우시안 분포를 기반으로 경계선 픽셀에 더 높은 가중치를 부여하여 학습을 집중
→ 경계를 더 정교하게 예측할 수 있도록 유도

Contents

01
Background

02
Introduction

03
Methodology

**04
Experiments**

05
Application in the
Medical Domain

Experiments

EM Segmentation challenge

Warping Error : 신경 조직의 구조적 왜곡 정도를 측정하는 지표

Rand Error : 클러스터링 기반으로 객체 간 차이를 측정하는 지표

Pixel Error : 픽셀 단위에서 예측과 정답의 차이를 측정하는 지표


Rank	Group name	Warping Error	Rand Error	Pixel Error
	** human values **	0.000005	0.0021	0.0010
1.	u-net	0.000353	0.0382	0.0611
2.	DIVE-SCI	0.000355	0.0305	0.0584
3.	IDSIA [1]	0.000420	0.0504	0.0613
4.	DIVE	0.000430	0.0545	0.0582
⋮				
10.	IDSIA-SCI	0.000653	0.0189	0.1027

전자 현미경 이미지에서 신경 구조 또는 세포 구조를 분할하는 문제를 다루는 대회

U-Net이 1위(0.000353 Warping Error) 기록

ISBI cell tracking challenge

세포의 성장, 분열 및 이동을 자동으로 추적하는 문제를 해결하는 대회
ISBI 2015 Cell Tracking Challenge에서 1위

$$\text{IoU} = \frac{\text{Area of Overlap}}{\text{Area of Union}}$$



평가지표: IOU (Intersection over union)

ground truth에 해당하는 bounding box와 prediction에 해당하는 bounding box에 대한 교차 영역의 겹치는 정도를 이용해서 값을 구한다.
이때 겹치는 영역이 넓을수록 IOU 값이 커지고 잘 예측한 것으로 평가할 수 있다.

Experiments

ISBI cell tracking challenge

Name	PhC-U373	DIC-HeLa
IMCB-SG (2014)	0.2669	0.2935
KTH-SE (2014)	0.7953	0.4607
HOUS-US (2014)	0.5323	-
second-best 2015	0.83	0.46
u-net (2015)	0.9203	0.7756



a,c: 입력 이미지

b,d: ground truth segmentation map

a,c와 같이 광학 현미경에서 얻은 이미지로

b,d와 같이 세포를 구별하는 task를 U-Net이 얼마나 잘 수행하는지 시험

a=Ph-U373

c=DIC-HeLa

Conclusion

U-Net은 다양한 생물의학 이미지 분할 문제에서 매우 우수한 성능을 보임
Elastic Deformation을 활용한 데이터 증강 덕분에 적은 데이터로도 학습 가능
NVidia Titan GPU (6GB)에서 10시간 학습→빠르고 효율적인 모델


∴ U-Net은 의료 영상 분석 및 다양한 이미지 분할 문제에서 표준 모델로 자리 잡음

Experiments


Conclusion

왜 의료용 이미지에서 U-Net을 사용할까?


- 의료 영상에서는 전체적인 맥락과 세밀한 경계를 동시에 고려하는 것이 중요함
- U-Net은 Skip connection을 통해 정보 손실 없이 국소적(Local)+전역적(Global) 특징을 모두 활용할 수 있음




Purple areas: true positive (TP); Yellow areas: false negative (FN); Green areas: false positive (FP).



(a) UNet
(Plain skip connections)



(b) UNet++
(Nested and dense skip connections)



(c) UNet 3+
(Full-scale skip connections)

Contents

01
Background

02
Introduction

03
Methodology


04
Experiments

**05
Application in the
Medical Domain**

Application in the Medical Domain

Application U-Net


- Dataset: **ISBI 2012 em segmentation challenge**
 - Image size
 - 512 x 512 x 1
 - Number of samples
 - Total: 30 frames
 - Train: 24 frames
 - Val: 3 frames
 - Test: 3 frames
 - Augmentation
 - Random Flip
 - Horizontal
 - Vertical
 - Label - Pixel 값에 의해
 - 0 - Membrane
 - 1 - Non - membrane



Application in the Medical Domain

Application U-Net

- Model
 - Paper에 나온 구조 그대로 구현
 - 단, Augmentation에서 elastic deformed는 구현 X
 - Hyper Parmas
 - Optimizer
 - Adam 활용
 - Loss func
 - Binary Cross Entropy 활용
 - Epoch
 - 100 epochs 설정
 - EarlyStopping 활용
 - patience 10으로 설정




Application in the Medical Domain

Application U-Net

- 성능 지표 - epoch 68th 기준

- Accuracy
 - 0.9028
- Recall
 - 0.9590
- Precision
 - 0.9164
- Specificity
 - 0.7218
- F-1 score
 - 0.9372



Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Gengeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Background
 - 유방암 검진 과정에서 DBT 재구성 수행
 - 해당 과정에서 DBT slice가 급증
 - 이를 수작업으로 **Segmentation** 하기에는 어려움이 존재
- Goal
 - **Automatic mass segmentation framework** 구축
 - TPR : FPR : F-Score : IOU = 0.911 : 0.003 : 0.911 : 0.900
 - 수작업 없이 **Mass segmentation**에서 높은 성능 기록

Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Introduction
 - 유방암 검진 과정
 - 정기 검진과 조기 검진이 중요
 - 유방 조직의 특성 상 이상 징후를 정확하게 탐지하기 어려움
 - 더불어 때때로 유방의 기능적 조직이 병변과 유사하게 보일 수 있음
 - DBT 2D slice를 3D로 재구성하여 조직 중첩을 낮추고 비교적 적은 방사선량으로 Mass를 탐지할 수 있음
 - 증가하는 Slice를 Segmentation 하는 성능이 중요
- Before
 - DCNN을 통한 Segmentation 기법 연구 수행
 - **Computational extensiveness**
 - Patch 추출 과정에서 Sliding window 기법은 연산량 증가
 - **Decreased resolution**
 - Pooling 기법에 의해서 출력 이미지의 Resolution 감소로 인한 feature 손실

Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- This Paper
 - U-Net을 활용한 AMS 제안
 - U-Net의 Architecture 특징으로 인해서
 - Decreased resolution 최소화
 - Multi-scale context 보존
 - Highly detailed segmentation 가능
 - 적은 데이터셋으로 학습 성능이 우수
 - DCNN보다 빠른 실시간 처리량과 더 좋은 분할 성능





Fig. 1 Overview of AMS-U-Net.

Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Methodology
 - **Pre processing** + U-Net + Post processing
 - DBT slice 해상도는 매우 높지만 **mass region**이 해상도에 비해 **매우 작음**
 - DBT slice를 그저 **단순하게 Resizing**하게 되는 경우 해상도 감소




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Methodology
 - Pre processing + U-Net + Post processing
 - Pre processing
 - Empty canvas creation
 - 동일한 크기의 빈 캔버스 생성
 - Image alignment
 - 각 원본 이미지를 캔버스 오른쪽을 기준으로 정렬
 - Patch division
 - 각 이미지를 4개의 동일한 크기 패치로 나눔
 - Ground truth processing
 - 원본 이미지 전처리 과정과 동일
 - 전처리 된 이미지와 실제 레이블 간의 일관성 유지




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Methodology
 - Pre processing + **U-Net** + Post processing
 - U-Net**
 - Model input
 - 1024 x 1024 x 1
 - Encoder - Downsampling
 - 2 개의 3 x 3 conv
 - ReLU function
 - 2 x 2 Max-pooling을 통한 Downsampling
 - Decoder - Upsampling
 - 2 개의 3 x 3 conv
 - ReLU function
 - 2 x 2 Up-conv을 통한 Upsampling
 - Output
 - 1 x 1 conv를 통한 Segmentation map 생성




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Methodology
 - Pre processing + U-Net + **Post processing**
 - DBT slice의 낮은 대비로 인해서 주변 Region과 Mass가 유사하여 **Segmentation 성능 저하**
 - **Post processing**
 - Gaussian filter
 - 노이즈를 효과적으로 줄이면서 객체 경계 보존
 - OTSU thresholding
 - 남아있는 노이즈 제거 및 배경과 객체 분할




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Methodology
 - Pre processing + U-Net + **Post processing**
 - **Post processing**
 - Gaussian filter
 - 노이즈를 효과적으로 줄이면서 객체 경계 보존
 - OTSU thresholding
 - 남아있는 노이즈 제거 및 배경과 객체 분할




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Methodology
 - Pre processing + U-Net + **Post processing**
 - **Post processing**
 - Gaussian filter
 - 노이즈를 효과적으로 줄이면서 객체 경계 보존
 - OTSU thresholding
 - 남아있는 노이즈 제거 및 배경과 객체 분할




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)


- Methodology
 - Pre processing + U-Net + **Post processing**
 - **Post processing**
 - Gaussian filter
 - 노이즈를 효과적으로 줄이면서 객체 경계 보존
 - OTSU thresholding
 - 남아있는 노이즈 제거 및 배경과 객체 분할




(a)




(b)



(c)



(d)




(e)

Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)


- Methodology
 - Pre processing + U-Net + **Post processing**
 - **Post processing**
 - Gaussian filter
 - 노이즈를 효과적으로 줄이면서 객체 경계 보존
 - OTSU thresholding
 - 남아있는 노이즈 제거 및 배경과 객체 분할




(a)



(b)



(c)



(d)



(e)

Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Gengeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Experiment

- Dataset - 원내 데이터 활용

- 50명의 환자에서 얻은 DBT 이미지를 활용

- Train: 25 개

- Test: 25 개

- Augmentation 수행

- Rotation

- Width/Height shift

- Shear

- Horizontal flip


- **TPR** - 0.911 ± 0.027

- **FPR** - 0.003 ± 0.001

- **F-Score** - 0.911 ± 0.033

- **IoU** - 0.900 ± 0.036

- **Hausdorff distance(95%)** - 5.82 ± 1.172



Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Experiment
 - Red line
 - Pre-processing만 수행한 경우
 - Blue line
 - OTSU threshold만 수행한 경우
 - Pre-processing만 수행한 경우에 비해 객체 식별 능력 향상
 - Green line
 - Gaussian filter + OTSU threshold 모두 적용한 경우
 - Gaussian filter를 함께 활용하여 객체의 경계 분할에 효과적임




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Experiment
 - a - Raw image
 - b - Ground truth
 - 방사선 전문의가 수동으로 Segmentation
 - c - AMS-U-Net predict
 - Ground Truth의 파란색 윤곽선과 매우 유사
 - 병변의 모양과 위치를 정확하게 포착
 - d - c 이미지 확대




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Experiment
 - a - Raw image
 - b - Ground truth
 - c - AMS-U-Net predict
 - d - Pre-processing만 수행한 경우
 - e - Ground truth
 - f - Post-processing까지 수행한 경우
 - g - Ground truth(red) & Predict(orange)




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Experiment
 - a - Raw image
 - b - Ground truth
 - c - AMS-U-Net predict
 - d - Pre-processing만 수행한 경우
 - e - Ground truth
 - f - Post-processing까지 수행한 경우
 - g - Ground truth(red) & Predict(orange)




Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Experiment

- a - Raw image
- b - Ground truth
- c - AMS-U-Net predict
- d - Pre-processing만 수행한 경우
- e - Ground truth
- f - Post-processing까지 수행한 경우
- g - Ground truth(red) & Predict(orange)



Application in the Medical Domain

AMS-U-Net: automatic mass segmentation in digital breast tomosynthesis via U-Net

Ahmad Qasem,^a Genggeng Qin,^b and Zhiguo Zhou (Journal of Medical Imaging)

- Conclusion
 - **Pre-processing**
 - 영상 해상도를 유지하고 객체와 배경 사이의 비율 개선
 - 입력 이미지에 대한 일관성 부여
 - **U-Net**
 - 적은 연산량과 실시간 처리량 우수
 - 적은 데이터셋으로 높은 성능 기록
 - 더 자세한 Segmentation이 가능
 - Multi-scale context 보존
 - **Post-processing**
 - 노이즈 제거로 인한 객체 경계 분할 성능 향상

QnA