

DDPM - Backbone Paper Review

홍창희, 박민선

July. 25. 2025

Medical AI Research Center

Contents

01
Introduction

02
Background

03
Methodology

04
Experiments

05
Application in the
Medical Domain

Contents

01
Introduction

02
Background

03
Methodology


04
Experiments

05
Application in the
Medical Domain

Introduction

Diffusion Model

Diffusion process



- 특정한 데이터의 패턴이 서서히 반복적인 과정을 거쳐 와해되는 과정을 diffusion process라 명명
- Deep Unsupervised Learning using Nonequilibrium Thermodynamics(2015, ICML)에서 비지도학습을 위한 방법론으로 첫 활용
- 대표적인 비지도학습 방법론인 이미지 생성 task에서 높은 성능을 보이며 주목을 받음

Prerequisite – Markov chain

- Markov 성질: "특정 상태의 확률 (t+1)은 오직 현재(t)의 상태에 의존한다"
- Ex) 오늘 습도가 N%이니 (현재 데이터) 내일 비가 올 확률은 M%이다 (예측)

$$P[s_{t+1}|s_t] = P[s_{t+1}|s_1, \dots, s_t]$$




- Forward: $q(x_t|x_{t-1})$
- Reverse: $p_\theta(x_{t-1}|x_t)$
- 모두 1-step transition만 고려하는 1차 마코프 체인

Introduction

Compare with extra Generative Model

모델	주요 특성
GAN	판별자와 생성자의 경쟁 → 직접 데이터 생성
VAE	인코더-디코더 구조로 잠재변수 추정
Flow	역변환 가능한 함수로 학습
Diffusion	점진적 노이즈 추가 후, 노이즈 제거 역과정 학습



✓ Diffusion 모델은 데이터를 직접 생성하는 대신, 노이즈에서 출발해 점진적으로 복원한다는 방식으로 기존 생성 모델과 차별화됨

Contents

01
Introduction

02
Background

03
Methodology


04
Experiments

05
**Application in the
Medical Domain**

Background

Diffusion process overview

- Diffusion model은 Generative model로서 학습된 데이터의 패턴을 생성해내는 역할을 함
- 패턴 생성 과정을 학습하기 위해 고의적으로 패턴을 무너트리고(Noising), 이를 다시 복원하는 조건부 PDF를 학습(Denoising)




$q(X_t | X_{t-1})$ 로 부터는 조건부가 바뀐 $q(X_{t-1} | X_t)$ 는 Inference과정에서 활용할 수 없음
다만, $q(X_t | X_{t-1})$ 가 gaussian이면, $q(X_{t-1} | X_t)$ 도 gaussian이라는 점은 이미 증명됨 (β_t 가 매우 작을 때)

Background

Diffusion process overview


- Diffusion model은 Generative model로서 학습된 데이터의 패턴을 생성해내는 역할을 함
- 패턴 생성 과정을 학습하기 위해 고의적으로 패턴을 무너트리고(Noising), 이를 다시 복원하는 조건부 PDF를 학습(Denoising)



- $p_\theta(X_{t-1} | X_t)$ 를 상정해 $q(X_{t-1} | X_t)$ 를 approximation
- 따라서 Diffusion model은 $p_\theta(X_{t-1} | X_t) \approx q(X_{t-1} | X_t)$ 되도록 학습

Background

Diffusion process overview



- 생성에 활용되는 조건부 확률 분포 $P_\theta(x | z)$ 을 학습하기 위해 Diffusion process $q(z | x)$ 를 활용

Contents

01
Introduction

02
Background

03
Methodology

04
Experiments


05
**Application in the
Medical Domain**

Methodology

Diffusion process – Forward

- **Diffusion process** 는 Contitioanl Gaussian의 joint-distribution으로서, $\mathbf{X}_0$ 를 조건부로 latent variables($\mathbf{X}_{1:T}$)를 생성해내는 과정
- 주입되는 gaussian noise 크기는 사전적으로 정의되고, 이를 β_t 로 표기

$$q(\mathbf{X}_{1:T} | \mathbf{X}_0) := \prod_{t=1}^T q(\mathbf{X}_t | \mathbf{X}_{t-1}), \quad q(\mathbf{X}_t | \mathbf{X}_{t-1}) := N(\mathbf{X}_t; \mu_{\mathbf{X}_{t-1}}, \Sigma_{\mathbf{X}_{t-1}}) := N(\mathbf{X}_t; \sqrt{1 - \beta_t} \mathbf{X}_{t-1}, \beta_t \cdot I)$$




Methodology

Diffusion process – Reverse

- *Reverse process* 는 Diffusion process의 역(reverse) 과정으로, **gaussian noise를 제거**해가며 특정한 패턴을 만들어가는 과정

$$p_{\theta}(X_{0:T}) := p(X_T) \prod_{t=1}^T q(X_{t-1} | X_t), \quad p_{\theta}(X_{t-1} | X_t) := N(X_{t-1}; \underbrace{\mu_{\theta}(X_t, t)}_{\text{학습 대상}}, \underbrace{\Sigma_{\theta}(X_t, t)}_{\text{학습 대상}})$$

학습 대상
(mean & variance function)



Methodology

■ Diffusion process – Reverse

$$p_{\theta}(X_{0:T}) := p(X_T) \prod_{t=1}^T q(X_{t-1} | X_t), \quad p_{\theta}(X_{t-1} | X_t) := N(X_{t-1}; \mu_{\theta}(X_t, t), \Sigma_{\theta}(X_t, t))$$



How ???

$$Loss_{diffusion} := D_{KL}(q(z | x_0) || P_{\theta}(z)) + \sum_{t=2} D_{KL}(q(x_{t-1} | x_t, x_0) || P_{\theta}(x_{t-1} | x_t)) - E_q[\log P_{\theta}(x_0 | x_1)]$$

$$:= \text{Negative log likelihood } (= \mathbb{E}_{x_T \sim q(x_T | x_0)} [-\log p_{\theta}(x_0)])$$

Methodology

■ Diffusion process – Loss

$$\begin{aligned}\mathbb{E}_{x_{1:T} \sim q(x_{1:T}|x_0)} [-\log p_\theta(x_0)] &= \mathbb{E}_{x_T \sim q(x_T|x_0)} \left[-\log \frac{p_\theta(x_0, x_1, x_2, \dots, x_T)}{p_\theta(x_1, x_2, x_3, \dots, x_T | x_0)} \right] \quad :: \text{Bayes rule, } p_\theta(x_T | x_0) = \frac{p_\theta(x_T, x_0)}{p_\theta(x_0)} \\&= \mathbb{E}_{x_T \sim q(x_T|x_0)} \left[-\log \frac{p_\theta(x_0, x_1, x_2, \dots, x_T)}{q(x_{1:T} | x_0)} \cdot \frac{q(x_{1:T} | x_0)}{p_\theta(x_1, x_2, x_3, \dots, x_T | x_0)} \right] \\&\leq \mathbb{E}_{x_T \sim q(x_T|x_0)} \left[-\log \frac{p_\theta(x_0, x_1, x_2, \dots, x_T)}{q(x_{1:T} | x_0)} \right] \quad :: \text{KL divergence} > 0, \text{ “ELBO”} \\&= \mathbb{E}_{x_T \sim q(x_T|x_0)} \left[-\log \frac{p_\theta(x_{0:T})}{q(x_{1:T} | x_0)} \right] \quad :: \text{Notation}\end{aligned}$$

Methodology

Diffusion process – Loss

$$= \mathbb{E}_{x_T \sim q(x_T | x_0)} \left[-\log \frac{p_\theta(x_T) \prod_{t=1}^T p_\theta(x_{t-1} | x_t)}{\prod_{t=1}^T q(x_t | x_{t-1})} \right]$$

$$= \mathbb{E}_{x_{1:T} \sim q(x_{1:T} | x_0)} \left[-\log p_\theta(x_T) - \sum_{t=1}^T \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_t | x_{t-1})} \right]$$

$$= \mathbb{E}_{x_{1:T} \sim q(x_{1:T} | x_0)} \left[-\log p_\theta(x_T) - \sum_{t=2}^T \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_t | x_{t-1})} - \log \frac{p_\theta(x_0 | x_1)}{q(x_1 | x_0)} \right]$$

$$= \mathbb{E}_{x_{1:T} \sim q(x_{1:T} | x_0)} \left[-\log p_\theta(x_T) - \sum_{t=2}^T \log \left(\frac{p_\theta(x_{t-1} | x_t)}{q(x_{t-1} | x_t, x_0)} \cdot \frac{q(x_{t-1} | x_0)}{q(x_t | x_0)} \right) - \log \frac{p_\theta(x_0 | x_1)}{q(x_1 | x_0)} \right]$$

$$q(x_t | x_{t-1}) = q(x_t | x_{t-1}, x_0)$$

:: Markov chain property

$$= \frac{q(x_t, x_{t-1}, x_0)}{q(x_{t-1}, x_0)}$$

:: Bayes rule

$$= \frac{q(x_{t-1}, x_t, x_0)}{q(x_{t-1}, x_0)} \cdot \frac{q(x_t, x_0)}{q(x_t, x_0)}$$

$$= q(x_{t-1} | x_t, x_0) \cdot \frac{q(x_t, x_0)}{q(x_{t-1}, x_0)}$$

Methodology

■ Diffusion process – Loss

$$\begin{aligned} &= \mathbb{E}_{x_{1:T} \sim q(x_{1:T}|x_0)} \left[-\log p_\theta(x_T) - \sum_{t=2}^T \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_{t-1} | x_t, x_0)} - \sum_{t=2}^T \log \frac{q(x_{t-1} | x_0)}{q(x_t | x_0)} - \log \frac{p_\theta(x_0 | x_1)}{q(x_1 | x_0)} \right] \\ &= \mathbb{E}_{x_{1:T} \sim q(x_{1:T}|x_0)} \left[-\log p_\theta(x_T) - \sum_{t=2}^T \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_{t-1} | x_t, x_0)} - \log \frac{q(x_1 | x_0)}{q(x_T | x_0)} - \log \frac{p_\theta(x_0 | x_1)}{q(x_1 | x_0)} \right] \\ &= \mathbb{E}_{x_{1:T} \sim q(x_{1:T}|x_0)} \left[-\log \left(\frac{p_\theta(x_T)}{q(x_T | x_0)} \right) - \sum_{t=2}^T \log \frac{p_\theta(x_{t-1} | x_t)}{q(x_{t-1} | x_t, x_0)} - \log p_\theta(x_0 | x_1) \right] \\ &\therefore \text{Loss}_{Diffusion} = \mathbb{E}_q \left[D_{\text{KL}}(q(\mathbf{x}_T | \mathbf{x}_0) \parallel p(\mathbf{x}_T)) + \sum_{t>1} D_{\text{KL}}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)) - \log p_\theta(\mathbf{x}_0 | \mathbf{x}_1) \right] \end{aligned}$$

Methodology

■ Diffusion process – Loss

$$\therefore \text{LOSS}_{\text{Diffusion}} = \mathbb{E}_q \left[\overset{L_T}{D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p(\mathbf{x}_T))} + \sum_{t>1}^{\overset{L_{1:T-1}}{D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))}} - \log p_\theta(\mathbf{x}_0|\mathbf{x}_1) \overset{L_0}{} \right]$$

L_T : 가장 마지막 단계 x_T 에 대해 $q(x_T|x_0)$ 가 prior 분포 $p(x_T)$ 와 얼마나 다른지 나타냄

$L_{1:T-1}$: Forward posterior $q(x_{t-1}|x_t, x_0)$ 는 정해져 있고 reverse model $p_\theta(x_{t-1}|x_t)$ 는 학습 대상임

L_0 : decoder term으로 noisy한 x_1 에서 clean data x_0 를 복원하는 log likelihood

$$\boxed{\text{LOSS}_{\text{DDPM}} = \mathbb{E}_{x_0, \epsilon} \left[\left| \epsilon - \epsilon_\theta \left(\sqrt{\tilde{\alpha}_t} + \sqrt{1 - \tilde{\alpha}_t} \epsilon, t \right) \right|^2 \right]} \leftarrow L_{1:T-1}$$

■ Diffusion process – Loss (L_T)

$$L_T = D_{\text{KL}}(q(\mathbf{x}_T \mid \mathbf{x}_0) \parallel p(\mathbf{x}_T))$$

1. Forward process (Markov chain):

$$q(x_t \mid x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t \mathbf{I})$$

2. Marginal form (closed-form for all steps):

$$q(x_t \mid x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) \mathbf{I}) \quad \text{where} \quad \bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s)$$

- Forward process의 분산 $\beta_t \rightarrow$ 논문에서는 고정된 상수로 설정하고 실험함
- 이로 인해 posterior $q(x_T \mid x_0)$ 역시 학습되지 않음
- 따라서 L_T 항은 학습 중 일정한 상수로 간주되며 무시 가능함

■ Diffusion process – Loss (L_0)

Data Scaling (Reverse Decoder)

- 원본 이미지 데이터를 $[-1,1]$ 로 스케일링하여 학습에 사용함
- 마지막 복원 단계 $p_\theta(\mathbf{x}_0|\mathbf{x}_1)$ 도 같은 스케일로 처리
- 복원 확률은 가우시안 분포로 가정하고 이산적인 $\mathbf{x}_0$ 를 위한 로그 우도는 연속분포의 적분으로 계산함
- Noise 없이 $\mu_\theta(\mathbf{x}_1, 1)$ 만으로 복원 가능 $\rightarrow$ 효율적인 L_0 구성 가능

$$p_\theta(\mathbf{x}_0|\mathbf{x}_1) = \prod_{i=1}^D \int_{\delta_-(x_0^i)}^{\delta_+(x_0^i)} \mathcal{N}(x; \mu_\theta^i(\mathbf{x}_1, 1), \sigma_1^2) dx$$

$$\delta_+(x) = \begin{cases} \infty & \text{if } x = 1 \\ x + \frac{1}{255} & \text{if } x < 1 \end{cases} \quad \delta_-(x) = \begin{cases} -\infty & \text{if } x = -1 \\ x - \frac{1}{255} & \text{if } x > -1 \end{cases}$$

Methodology

■ Diffusion process – Loss ($L_{1:T-1}$)

$$L_{t-1} = \sum_{t>1} D_{\text{KL}}(q(x_{t-1} | x_t, x_0) \| p_{\theta}(x_{t-1} | x_t))$$

$$q(x_{t-1} | x_t, x_0) = \frac{q(x_t | x_{t-1}, x_0) \cdot q(x_{t-1} | x_0)}{q(x_t | x_0)}$$

$$\propto \exp \left(-\frac{1}{2} \left[\frac{(x_t - \sqrt{\bar{\alpha}_t} x_{t-1})^2}{\beta_t} + \frac{(x_{t-1} - \sqrt{\bar{\alpha}_{t-1}} x_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(x_t - \sqrt{\bar{\alpha}_t} x_0)^2}{1 - \bar{\alpha}_t} \right] \right)$$

$$= \exp \left(-\frac{1}{2} \left[\frac{x_t^2 - 2\sqrt{\bar{\alpha}_t} x_t x_{t-1} + \bar{\alpha}_t x_{t-1}^2}{\beta_t} + \frac{x_{t-1}^2 - 2\sqrt{\bar{\alpha}_{t-1}} x_{t-1} x_0 + \bar{\alpha}_{t-1} x_0^2}{1 - \bar{\alpha}_{t-1}} - \frac{(x_t - \sqrt{\bar{\alpha}_t} x_0)^2}{1 - \bar{\alpha}_t} \right] \right)$$

$$= \exp \left(-\frac{1}{2} \left[\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) x_{t-1}^2 - \left(\frac{2\sqrt{\bar{\alpha}_t}}{\beta_t} x_t + \frac{2\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} x_0 \right) x_{t-1} + C(x_t, x_0) \right] \right)$$

✓ Multivariate Normal distribution

$$\frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu)^{\top} \Sigma^{-1} (x - \mu) \right)$$

Methodology

■ Diffusion process – Loss ($L_{1:T-1}$)

- 분산은 우리가 알고있는 α, β 로 구성되므로 상수취급 할 수 있음
- 따라서, q와 p의 평균 차이만으로 loss 식 단순화 할 수 있음

$$\begin{aligned}\tilde{\mu}_t &= \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_t \right) \\ \tilde{\beta}_t &= \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \cdot \beta_t\end{aligned}$$

$$\sum_{t=2} D_{KL}(q(x_{t-1} | x_t, x_0) || P_{\theta}(x_{t-1} | x_t))$$

$$q(x_{t-1} | x_t, x_0) = N(x_{t-1}; \tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t \cdot I)$$

$$p_{\theta}(x_{t-1} | x_t) = N(x_{t-1}; \mu_{\theta}(x_t, t), \beta_t \cdot I)$$

$$\mathbb{E}_q \left[\frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) - \mu_{\theta}(\mathbf{x}_t, t)\|^2 \right]$$


Denoising Process

Methodology

■ Diffusion process – Loss

$$\begin{aligned} LOSS_{Diffusion} &= D_{KL}(q(z | x_0) || P_{\theta}(x_0 | z)) - E_{z \sim q(z|x)}[\log P_{\theta}(z)] \\ &= D_{KL}(q(z | x_0) || P_{\theta}(z)) + \sum_{t=2} D_{KL}(q(x_{t-1} | x_t, x_0) || P_{\theta}(x_{t-1} | x_t)) - E_q[\log P_{\theta}(x_0 | x_1)] \end{aligned}$$

Regularizer on Encoder *Denoising Process* *Reconstruction on Decoder*



DDPM에서는 Loss가 굉장히 간단한 식으로 정의됨

$$LOSS_{DDPM} = \mathbb{E}_{x_0, \epsilon} \left[\left| \epsilon - \epsilon_{\theta} \left(\sqrt{\tilde{\alpha}_t} + \sqrt{1 - \tilde{\alpha}_t} \epsilon, t \right) \right|^2 \right]$$

■ Langevin dynamics

$$x_{t+1} = x_t + \frac{\epsilon}{2} \nabla_x \log p(x_t) + \sqrt{\epsilon} z_t \quad : \text{Langevin dynamics}$$

- 확률분포 $p(x)$ 로부터 샘플을 생성하는 방법 중 하나로, 데이터의 로그밀도 $\nabla_x \log p(x_t)$ 에 따라 움직이고 노이즈를 섞는 방식
- 데이터에 점진적으로 noise를 제거하며 확률적으로 샘플링하는 과정임.

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(x_t, t) \right) + \sigma_t z \quad : \text{Reverse process of DDPM}$$

- DDPM의 역과정 수식은 Langevin dynamics와 유사한 구조를 가짐
 - $\epsilon_{\theta}(x_t, t)$ 는 데이터 분포의 gradient를 근사하는 역할을 하며, 이를 이용해 노이즈를 제거하는 방향으로 샘플을 이동시킴
 - 따라서 DDPM의 샘플링은 학습된 gradient를 따라 이동하면서 노이즈를 점차 제거하는 Langevin dynamics의 형태로 볼 수 있음
- DDPM은 ‘학습된 gradient’를 따라 노이즈를 제거하며 샘플을 생성하는 모델이며,
이 구조가 Langevin dynamics와 유사하다는 것은 DDPM이 일종의 확률적 최적화 혹은 샘플링 알고리즘처럼 작동한다는 뜻임.

Contents

01
Introduction

02
Background

03
Methodology

04
Experiments

05
**Application in the
Medical Domain**

Experiments

Sample quality

Table 1: CIFAR10 results. NLL measured in bits/dim.

Model	IS	FID	NLL Test (Train)
Conditional			
EBM [11]	8.30	37.9	
JEM [17]	8.76	38.4	
BigGAN [3]	9.22	14.73	
StyleGAN2 + ADA (v1) [29]	10.06	2.67	
Unconditional			
Diffusion (original) [53]			≤ 5.40
Gated PixelCNN [59]	4.60	65.93	3.03 (2.90)
Sparse Transformer [7]			2.80
PixelIQN [43]	5.29	49.46	
EBM [11]	6.78	38.2	
NCSNv2 [56]		31.75	
NCSN [55]	8.87 ± 0.12	25.32	
SNGAN [39]	8.22 ± 0.05	21.7	
SNGAN-DDLS [4]	9.09 ± 0.10	15.42	
StyleGAN2 + ADA (v1) [29]	9.74 ± 0.05	3.26	
Ours (L , fixed isotropic Σ)	7.67 ± 0.13	13.51	< 3.70 (3.69)
Ours (L_{simple})	9.46 ± 0.11	3.17	≤ 3.75 (3.72)

*IS(Inception Score):


생성된 이미지의 품질과 다양성을 동시에 평가하는 지표.
값이 높을수록 생성된 이미지의 품질이 좋고 다양성도 높음.

*FID(Fréchet Inception Distance):

생성된 이미지 분포와 실제 이미지 분포 간의
유사성 또는 거리를 평가하는 지표.
값이 낮을수록 생성된 이미지가 실제 이미지와
분포적으로 더 유사하고 품질이 좋음

*NLL(Negative Log Likelihood):

실제 데이터 분포를 얼마나 잘 학습했는지,
즉 데이터 분포에 대한 모델의 정확성을 평가하는 지표.
값이 낮을수록 모델이 더 정확하게 분포를 학습한 것.



- DDPM의 FID score는 3.17로서 Unconditional 생성모델 중 가장 높은 sample quality를 보임
- 계수 Term을 제외한 경우(**Ours : L_{simple}**)는 제외하지 않은 경우(**Ours : L**)에 비해 NLL이 높지만, Sample quality(FID score)는 월등히 높음을 확인할 수 있음

Experiments

Reverse process parameterization and training objective ablation

Table 2: Unconditional CIFAR10 reverse process parameterization and training objective ablation. Blank entries were unstable to train and generated poor samples with out-of-range scores.

Objective	IS	FID
$\tilde{\mu}$ prediction (baseline)		
(1) L , learned diagonal Σ	7.28 ± 0.10	23.69
L , fixed isotropic Σ	8.06 ± 0.09	13.22
(2) $\ \tilde{\mu} - \tilde{\mu}_\theta\ ^2$	–	–
ϵ prediction (ours)		
(3) L , learned diagonal Σ	–	–
L , fixed isotropic Σ	7.67 ± 0.13	13.51
(4) $\ \tilde{\epsilon} - \epsilon_\theta\ ^2 (L_{\text{simple}})$	9.46 ± 0.11	3.17

$$(1) \quad \mathbb{E}_q \left[\frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) - \mu_\theta(\mathbf{x}_t, t)\|^2 \right]$$

$$(2) \quad \mathbb{E}_q \left[\|\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) - \mu_\theta(\mathbf{x}_t, t)\|^2 \right]$$

$$(3) \quad \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\underbrace{\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)}}_{\text{Coefficient term}} \left\| \epsilon - \epsilon_\theta \left(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right\|^2 \right]$$

$$(4) \quad \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\left\| \epsilon - \epsilon_\theta \left(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right\|^2 \right]$$

- (기존방식) $\tilde{\mu}$ 예측 목적식의 경우, fixed variance를 사용했을 때, 성능이 향상됨. but, 목적식의 간단화(simplification)에서는 성능이 매우 악화됨
- (제안한 방식) ϵ 예측 목적식의 경우, fixed variance를 사용할 경우 & 목적식의 간단화를 적용할 경우 성능이 크게 향상됨

Experiments

Reverse process parameterization and training objective ablation


ϵ prediction (ours)		
(3) [L , learned diagonal Σ	–	–
L , fixed isotropic Σ	7.67 ± 0.13	13.51
(4) $\ \tilde{\epsilon} - \epsilon_\theta\ ^2 (L_{\text{simple}})$	9.46 ± 0.11	3.17

$$(3) \quad \mathbb{E}_{\mathbf{x}_0, \epsilon} \left[\underbrace{\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)}}_{\text{Coefficient term}} \left\| \epsilon - \epsilon_\theta \left(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right\|^2 \right]$$

$$(4) \quad \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\left\| \epsilon - \epsilon_\theta \left(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t \right) \right\|^2 \right]$$

Small “t”

Large “t”




- 목적식 (3) : **Coefficient term** 은 t 가 증가할 수록 그 값이 작아지는 경향을 갖게 됨
 - 따라서 **Coefficient term** 이 존재할 경우, large t 시점(더 noisy)의 Loss가 상대적으로 down-weight 되는 효과가 발생
- 목적식 (4) : **Coefficient term**을 제거함으로써, large t 시점(더 noisy)의 Loss 비중을 더 높일 수 있음
 - 이를 통해 모델이 noise가 심한 이미지(large t 시점의 상태)의 denoising에 집중하도록 유도

Experiments


Conclusion

- Denoising score matching과 Langevin Dynamics의 연결을 통해 **Diffusion** 모델의 고품질 이미지 생성의 잠재력을 명확히 보여줌
- GAN과 같은 다른 생성모델에 비해 강한 학습 안정성을 가짐
- 여러 모달리티로의 확장 가능성


Future Research Directions



ex 1) Super-Resolution



ex 2) Inpainting



ex 3) Text Guided Img Gen

Contents

01
Introduction

02
Background

03
Methodology


04
Experiments

05
Application in the
Medical Domain

Application in the Medical Domain

Application DDPM




- Dataset: BloodMNIST
 - ❑ 2D 혈액 세포 분류용 데이터셋
 - ❑ Image size
 - 48x48x3
 - ❑ Number of samples
 - Total: 11,908
 - Train: 11,900
 - Val: 4
 - Test: 4



Application in the Medical Domain

Application DDPM

- Model
 - DDPM 논문과 동일하게 구현
- Epoch
 - 30으로 설정
 - Check point로 best model 저장
- Test
 - FID: 3.653



Application in the Medical Domain


Score-based diffusion models for accelerated MRI

Hyungjin Chung, Jong Chul Ye (Medical Image Analysis)

- Background
 - MRI 데이터를 얻을때, 원본 신호 데이터 전체를 획득하는데엔 오랜 시간이 걸림
 - 그로 인해 k-space 데이터를 부분적으로만 샘플링하여 빠르게 얻는 accelerated MRI를 많이 사용
 - 데이터 획득량을 줄이면 필연적으로 Aliasing으로 인해 이미지 품질이 저하되고 진단에 부적합해짐
- Goal
 - Accelerated MRI Reconstruction: 저품질의 accelerated MRI를 고품질의 MRI 이미지로 재구성함
 - Score-based Diffusion Model을 활용해 실제 임상 환경에 적용 가능하도록 함



(a) : 전체 샘플링 데이터




(b) : 부분 샘플링 데이터

Application in the Medical Domain


Score-based diffusion models for accelerated MRI

Hyungjin Chung, Jong Chul Ye (Medical Image Analysis)

- Before
 - Supervised Deep Learning(U-Net, DuDoRNet 등)
 - 기존 Diffusion Model
 - 복소수 형태인 raw K-space 데이터를 학습에 필요로 했음
- This Paper
 - Magnitude Image인 DICOM 데이터의 학습만으로 높은 성능 달성



(a) : Data in K-space
(복소수 Image)



(b) : Magnitude Image

Application in the Medical Domain

Score-based diffusion models for accelerated MRI

Hyungjin Chung, Jong Chul Ye (Medical Image Analysis)


- Methodology

- ✓ *Stochastic Differential Equations(SDE) + DDPM
*Score-based generative modeling through stochastic differential equations (2020)
Y Song, J Sohl-Dickstein, DP Kingma, A Kumar, S Ermon, B Poole

- 연속시간 SDE에서의 Denoising score matching 목적함수

$$\min_{\theta} \mathbb{E}_{t \sim \mathcal{U}(0,1)} \left[\lambda(t) \mathbb{E}_{\mathbf{x}(0)} \mathbb{E}_{\mathbf{x}(t)|\mathbf{x}(0)} \left[\left\| \underbrace{\mathbf{s}_{\theta}(\mathbf{x}(t), t)}_{\text{학습 score function}} - \underbrace{\nabla_{\mathbf{x}} \log p_{0t}(\mathbf{x}(t)|\mathbf{x}(0))}_{\text{실제 score function}} \right\|_2^2 \right] \right]$$

- 위 식으로 데이터 분포의 score function을 학습하고,
이 학습된 score function을 사용하여 SDE를 역방향으로 풀면서
(inference 하며) 데이터를 생성함



Application in the Medical Domain

Score-based diffusion models for accelerated MRI

Hyungjin Chung, Jong Chul Ye (Medical Image Analysis)

- Experiments
 - Dataset: fastMRI knee dataset
 - Train
 - 대략 25,000 slices
 - 973개의 각 volume에서 처음과 마지막 5개의 slice는 제외
 - Test
 - 30 volumes from Val set
 - raw k-space data, Magnitude Image(fully-sampled), 복소수 Image(fully-sampled) 등을 포함

Application in the Medical Domain


Score-based diffusion models for accelerated MRI

Hyungjin Chung, Jong Chul Ye (Medical Image Analysis)

- Experiments

- 1. Real-valued Simulation study

- Magnitude Image로 score function 학습 후에, Magnitude Image 입력으로 reconstruction 실험
 - 마치 K-space에서 언더샘플링된 것처럼 이미지에 노이즈와 아티팩트를 인위적으로 추가하여 reconstruction하는 실험
 - 한계:
실제로 얻어지는 MRI는 k-space에서의 복소수 이미지이기 때문에, "Magnitude 데이터로 학습한 모델이 복소수 데이터도 처리할 수 있는가?"라는 질문에 직접 답해주지 못함



Application in the Medical Domain


Score-based diffusion models for accelerated MRI

Hyungjin Chung, Jong Chul Ye (Medical Image Analysis)

- Experiments

- 2. Complex-valued Single-coil Reconstruction

- Magnitude Image로 score function 학습 후에, 복소수 이미지 입력으로 reconstruction 실험
 - 복소수 데이터를 처리하는 Algorithm을 제시했기에 나올 수 있던 결과
 - "k-space 데이터 없이 Magnitude 데이터만으로도 높은 성능을 달성했다"는 Goal을 증명



Application in the Medical Domain

Score-based diffusion models for accelerated MRI

Hyungjin Chung, Jong Chul Ye (Medical Image Analysis)

Experiments

- Quantitative metrics of real-valued simulation study & single-coil complex-valued image experiment.

*PSNR(Peak Signal-to-Noise Ratio):

원본(ground truth) 이미지와 reconstructed 이미지 사이의 오차(noise)를 정량화하는 지표.
값이 높을수록 MSE가 낮다는 의미. 이미지 품질이 좋다는 것.

*SSIM(Structural Similarity Index Measure):

원본 이미지와 reconstructed 이미지 사이의 구조적인 유사성을 측정하는 지표.
1에 가까울수록 두 이미지가 구조적으로 매우 유사하다는 의미.

					TV	Supervised U-Net	DuDoRNet	Proposed	$p^* < 0.0001$
Simulation (real)	Uniform 1D	$\times 4$	PSNR [db]		27.55 $\pm$ 1.60	29.21 $\pm$ 2.09	30.79 $\pm$ 0.91	31.10 $\pm$ 1.60	TV, U-Net
			SSIM		0.667 $\pm$ 0.045	0.788 $\pm$ 0.030	0.796 $\pm$ 0.022	0.795 $\pm$ 0.036	
		$\times$	PSNR [db]		26.35 $\pm$ 1.74	27.40 $\pm$ 2.39	24.08 $\pm$ 1.80	28.37 $\pm$ 1.97	TV, U-Net, DuDoRNet
			SSIM		0.631 $\pm$ 0.052	0.722 $\pm$ 0.042	0.603 $\pm$ 0.037	0.771 $\pm$ 0.051	
		$\times 4$	PSNR [db]		30.77 $\pm$ 1.24	32.85 $\pm$ 1.25	33.01 $\pm$ 1.05	33.32 $\pm$ 1.22	TV, U-Net, DuDoRNet
			SSIM		0.752 $\pm$ 0.029	0.829 $\pm$ 0.023	0.858 $\pm$ 0.016	0.825 $\pm$ 0.028	
	Gaussian 1D	$\times$	PSNR [db]		28.87 $\pm$ 1.56	30.81 $\pm$ 1.37	30.46 $\pm$ 1.28	30.94 $\pm$ 1.17	TV, DuDoRNet
			SSIM		0.70 $\pm$ 0.041	0.779 $\pm$ 0.029	0.776 $\pm$ 0.025	0.761 $\pm$ 0.025	
		$\times$	PSNR [db]		23.19 $\pm$ 2.30	21.92 $\pm$ 4.51	25.29 $\pm$ 4.16	29.95 $\pm$ 2.04	TV, U-Net, DuDoRNet
			SSIM		0.599 $\pm$ 0.082	0.573 $\pm$ 0.173	0.643 $\pm$ 0.077	0.701 $\pm$ 0.071	
		$\times$	PSNR [db]		18.20 $\pm$ 2.80	17.43 $\pm$ 0.45	21.24 $\pm$ 2.09	29.58 $\pm$ 1.47	TV, U-Net, DuDoRNet
			SSIM		0.456 $\pm$ 0.096	0.451 $\pm$ 0.158	0.518 $\pm$ 0.046	0.678 $\pm$ 0.052	
	VD Poisson disk	$\times$	PSNR [db]		21.26 $\pm$ 0.96	23.47 $\pm$ 1.07	23.22 $\pm$ 0.93	31.83 $\pm$ 1.15	TV, U-Net, DuDoRNet
			SSIM		0.516 $\pm$ 0.038	0.606 $\pm$ 0.083	0.516 $\pm$ 0.063	0.769 $\pm$ 0.030	
		$\times$	PSNR [db]		19.56 $\pm$ 0.51	20.97 $\pm$ 1.73	22.84 $\pm$ 2.34	30.46 $\pm$ 1.21	TV, U-Net, DuDoRNet
			SSIM		0.517 $\pm$ 0.042	0.620 $\pm$ 0.054	0.561 $\pm$ 0.063	0.709 $\pm$ 0.035	
		$\times 8$	PSNR [db]		27.13 $\pm$ 1.91	30.90 $\pm$ 1.78	30.43 $\pm$ 0.79	31.95 $\pm$ 1.45	TV, U-Net, DuDoRNet
			SSIM		0.636 $\pm$ 0.041	0.801 $\pm$ 0.027	0.793 $\pm$ 0.024	0.812 $\pm$ 0.036	
Single-coil	Uniform1D	$\times 8$	PSNR [db]		24.38 $\pm$ 2.01	27.48 $\pm$ 1.66	24.72 $\pm$ 1.89	27.97 $\pm$ 2.03	TV, DuDoRNet
			SSIM		0.601 $\pm$ 0.090	0.720 $\pm$ 0.039	0.641 $\pm$ 0.055	0.738 $\pm$ 0.053	
		$\times$	PSNR [db]		28.39 $\pm$ 1.09	32.86 $\pm$ 1.23	33.46 $\pm$ 1.35	33.96 $\pm$ 1.27	TV, U-Net, DuDoRNet
			SSIM		0.679 $\pm$ 0.077	0.828 $\pm$ 0.024	0.856 $\pm$ 0.022	0.858 $\pm$ 0.028	
		$\times$	PSNR [db]		25.91 $\pm$ 3.21	30.80 $\pm$ 1.34	29.65 $\pm$ 1.76	30.82 $\pm$ 1.37	TV, DuDoRNet
			SSIM		0.622 $\pm$ 0.050	0.777 $\pm$ 0.028	0.777 $\pm$ 0.028	0.762 $\pm$ 0.034	
	Gaussian 2D	$\times$	PSNR [db]		20.09 $\pm$ 6.13	19.99 $\pm$ 5.12	21.53 $\pm$ 10.86	29.45 $\pm$ 2.97	TV, U-Net, DuDoRNet
			SSIM		0.592 $\pm$ 0.140	0.520 $\pm$ 0.187	0.541 $\pm$ 0.152	0.676 $\pm$ 0.118	
		$\times$	PSNR [db]		17.99 $\pm$ 3.15	17.24 $\pm$ 4.01	18.86 $\pm$ 5.51	26.15 $\pm$ 4.44	TV, U-Net, DuDoRNet
			SSIM		0.460 $\pm$ 0.250	0.436 $\pm$ 0.156	0.490 $\pm$ 0.192	0.587 $\pm$ 0.148	
		$\times$	PSNR [db]		20.90 $\pm$ 3.92	19.67 $\pm$ 1.72	22.91 $\pm$ 2.54	31.50 $\pm$ 1.24	TV, U-Net, DuDoRNet
			SSIM		0.626 $\pm$ 0.101	0.604 $\pm$ 0.067	0.643 $\pm$ 0.041	0.762 $\pm$ 0.030	
	VD Poisson disk	$\times$	PSNR [db]		22.13 $\pm$ 1.92	21.67 $\pm$ 1.06	23.95 $\pm$ 1.13	30.66 $\pm$ 1.30	TV, U-Net, DuDoRNet
			SSIM		0.616 $\pm$ 0.089	0.573 $\pm$ 0.098	0.593 $\pm$ 0.032	0.706 $\pm$ 0.035	

Score-based diffusion models for accelerated MRI

Hyungjin Chung, Jong Chul Ye (Medical Image Analysis)

- Conclusion
 - Score-based Diffusion + DDPM
 - 데이터 분포의 그래디언트(Score function)을 강력한 사전정보(prior)로 활용해 denoising을 성공시키는 방식으로 accelerated MRI를 위한 혁신적인 reconstruction 방법을 제시
 - Magnitude 이미지(DICOM)만으로 학습
 - Magnitude 이미지만으로의 학습으로부터 복소수 데이터를 reconstruction할 수 있게 함으로써, 기존 모델들의 K-space 데이터 의존성이라는 큰 장벽을 허물었음

QnA